



#### Objectif:

Acquérir une pratique élementaire d'outils permettant de traiter des données en Python, en vue de faciliter la pratique des TPs en cours de data-sciences, pour le développement des projets industriels qui en ont besoin, pour le stage, et au delà...

#### Moyens:

- → Prendre en main des outils (Git, JupyterLab, RosettaHUB/AWS,...) et concepts indispensables tout au long des enseignements du MS autour de la data;
- →Travailler sur trois jeux de données : des nombres, du texte, des images ;



### Mastère SIO - Octobre 2019 - Projet Fil Rouge Sommaire



#### Sommaire:

- 1. Gestion de code source, GIT
- 2. Cycle de développement de code pour les data-sciences, **JupyterLab**
- 3.Le minimum vitale sur les "APIs"
- 4. Accès au Cloud via une API, boto3 & co.
- 5. Jeux de données ...
- 6.Description du mini projet (validation IPv4 & FRG)





#### Pourquoi a t-on besoin d'un gestionnaire de versions?

```
[$ echo "https://gitlab-student.centralesupelec.fr/" > gitlab.txt
[$ cp gitlab.txt gitlab2.txt
[$ echo "https://gitlab-research.centralesupelec.fr/" >> gitlab2.txt
[$ cat gitlab.txt
https://gitlab-student.centralesupelec.fr/
[$ cat gitlab2.txt
https://gitlab-student.centralesupelec.fr/
https://gitlab-research.centralesupelec.fr/
https://gitlab-research.centralesupelec.fr/
}
```

Différences entre l'ancien et le nouveau

```
[$ diff gitlab.txt gitlab2.txt
1a2
> https://gitlab-research.centralesupelec.fr/
[$ diff gitlab2.txt gitlab.txt
2d1
< https://gitlab-research.centralesupelec.fr/
$</pre>
```

Différences entre le nouveau et l'ancien





#### Upgrade de l'ancienne vers la nouvelle?

Fabrication d'un "patch"

Application de ce patch et vérifications

Version initiale!!

#### Revenir à la version précédente est également possible :

```
[$ diff gitlab2.txt gitlab.txt > patch_new2old.txt
[$ patch gitlab2.txt patch_new2old.txt
patching file gitlab2.txt
[$ cat gitlab2.txt
https://gitlab-student.centralesupelec.fr/
```





Ces opérations basiques sont à considérer pour l'ensemble d'un projet :

- · Des dizaines, centaines, milliers .... de fichiers;
- De multiples évolutions du contenu de chaque fichiers;
- · De nombreux développeurs (et autres) qui interviennent sur le code ;
- · Plusieurs (beaucoup...) étapes majeures dans le produit :
  - \* Des changements d'architectures, de technologies utilisées...
  - ★ Des marqueurs d'étapes (versions...)
  - ★ nécessité maintenir simulnatément le code des version les plus récentes...

→ Nécessité d'un outil (manuellement c'est vite ingérable)!





Famille des gestionnaires (OpenSource) / modèles de fonctionnement

Modèles centralisés (serveur obligatoire): RCS, CVS, SVN...

Modèles distribués (serveur optionnel): GIT, BAZAAR, MERCURIAL,...

Les gestionnaires de versions quand ils sont adoptés ont généralement une très longue durée de vie (bien plus que les logiciels qu'ils permettent de gérer). Plusieurs décennies n'est pas rare (CVS, SVN - Subversion...)

« Git (2005) is not an acronym. Linus Torvalds developed Linux and he called it so. Then he developed version control system for it and named it "Git", which is an offensive English slang meaning "a stupid person". When asked about it, he said, "I'm an egotistical bastard, and I name all my projects after myself." »

Cf: https://en.wikipedia.org/wiki/Git

Site de référence pour GIT: https://git-scm.com/ et sa référece texte et vidéo: https://git-scm.com/book/en/v2/ et https://git-scm.com/videos/





GIT peut fonctionner en local et/ou utiliser un serveur centralisé

En pratique pour nous au SIO:

github.com: Site collaboratif, sorte de réseau social pour développeurs - Tout le monde voit tout le monde sur les projets opensources (« read-only » sauf pour le(s) propriétaire(s)) - Version payante pour rendre un projet privé;

gitlab-student.centralesupelec.fr (avec votre identifiant @student...)

Site collaboratif mais seulement à l'échelle du Campus de CS (c'est encouragé pour vos projets...).





En tant que gestionnaire de versions, GIT répond à quatre questions concernant les fichiers gérés :

#### 1. Qui ?

→ La(les) personnes qui effectue(nt) la(les) modification(s);

#### 2. Quand?

Tous les évènements sont datés et identifiables ;

#### 3.Quoi?

→ Ce qui change est tracé et identifiable ;

#### 4. Pourquoi?

→Un commentaire (optionnel) délivre une explication





Git fonctionne en mode distribué, c'est à dire :

- Fonctionne en mode local pour un seul développeur « local repository » vs dépôt local;
- Fonctionne en mode distant pour autant de développeurs que souhaité (1 mini) - « remote repository » vs dépôt distant

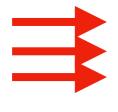
Les deux modes sont souvent mixés, à savoir un dépôt local est téléchargé depuis le dépôt distant par tous les intervenants et des opérations de mise à jour, vers et depuis le dépôt distant, sont régulièrement (ou pas) effectuées.





#### Deux approches pour démarrer :

- 1. « From scratch » c'est à dire à partir de rien (mkdir, git config, git init, etc..)
- 2. On part d'un projet existant pour le consulter vs le modifier. Là encore deux possibilités :
  - 1. Dépôt anonyme (c'est le cas le plus souvent sur github) en lecture seule
  - 2. Dépôt authentifié (c'est le cas sur gitlab-student.centralesupelec.fr)





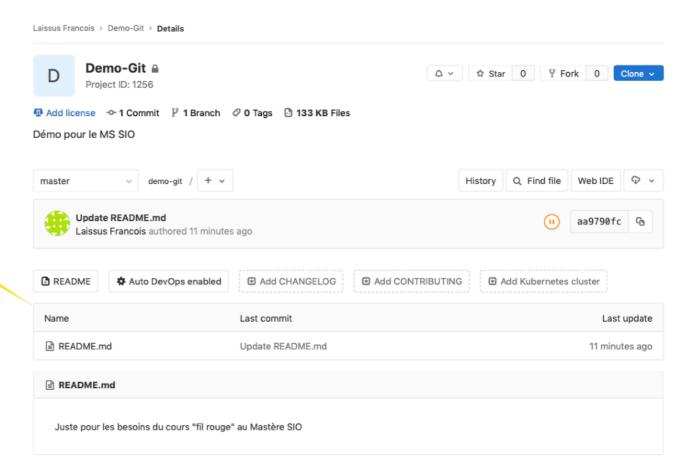


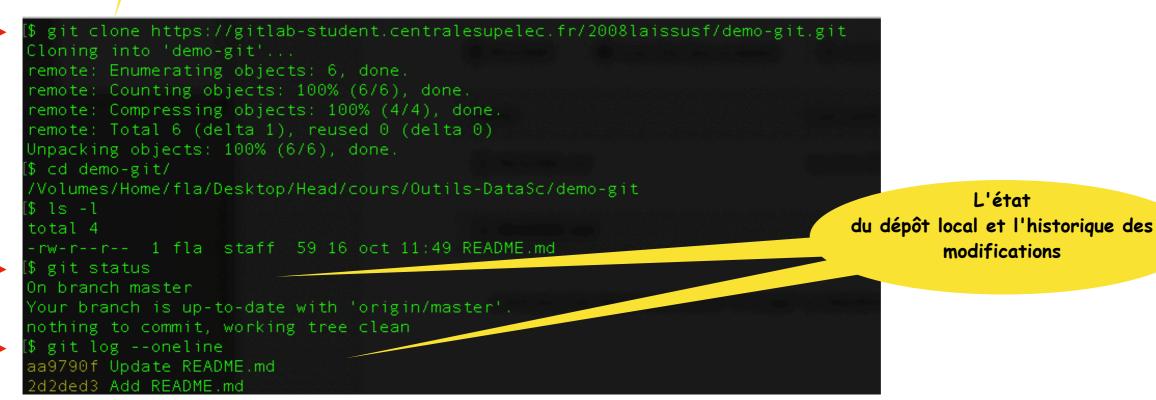
L'état

modifications



Accès en ligne de commandes, le même fichier est visible

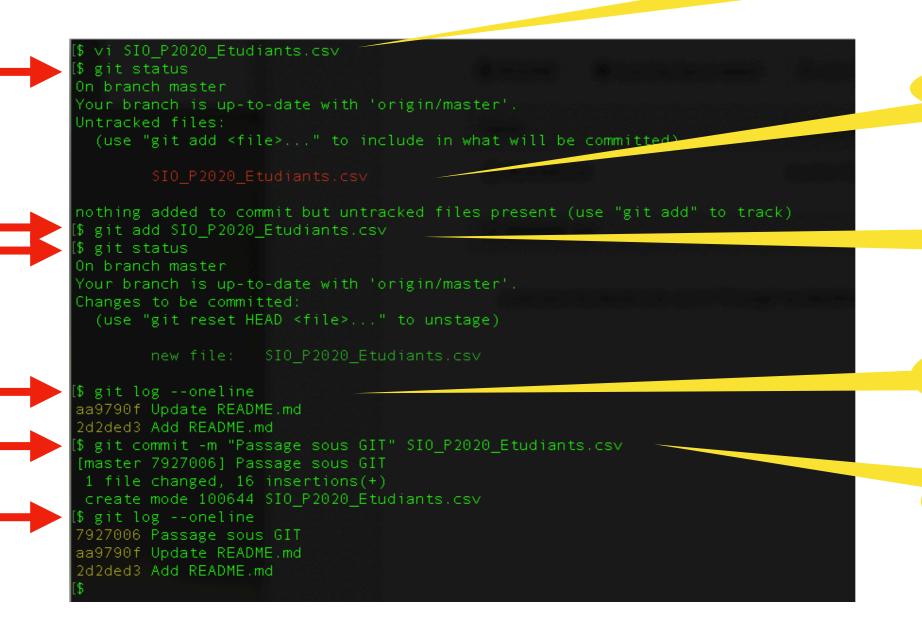








édition d'un nouveau fichier



il n'est pas (encore) indexé (staged)

'add' le prend en compte

Il n'est pas enregistré dans le repository

commit
l'ajoute à l'historique et dans le
repository



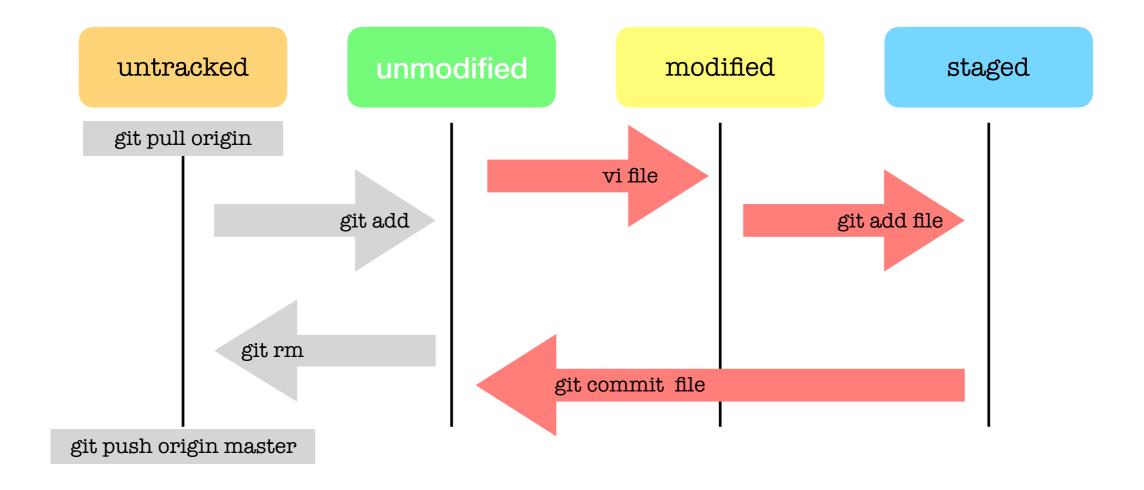








En résumé le cycle de vie d'un fichier (\*) (git status/add/commit/...)

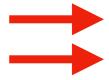


(\*) Figure utilisée un peu partout sans auteur initial bien défini...

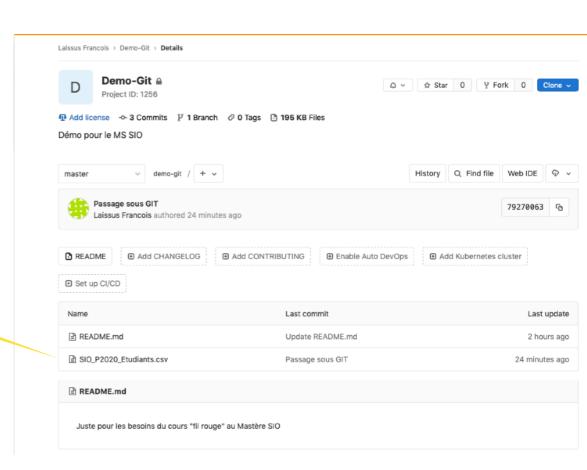




#### Et le "push" final pour mettre à jour de dépôt distant :



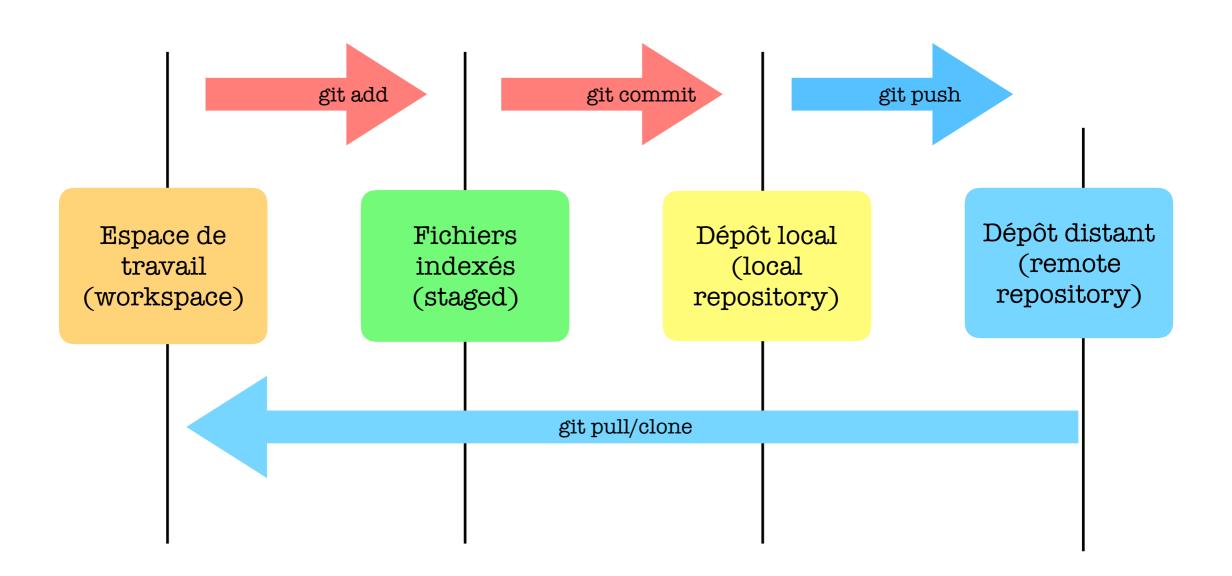
Immédiatement visible via l'interface web







#### En résumé(\*), avec un dépôt distant (comme sur la diapo précédente) :



(\*) Figure utilisée un peu partout, sans auteur initial bien défini...





#### Les branches

Dans un dépôt GIT on travaille toujours sur une branche, par défaut elle se nomme

Le cycle de développement d'un code est rarement linéaire :

- Besoin d'expérimenter un point, de corriger un bug, (...) sans remettre le fonctionnement /architecture de l'ensemble en question;
- Besoin de maintenir l'ensemble du projet selon plusieurs versions, par exemple une version spécifique par client, une version de test, une version en développement, etc...

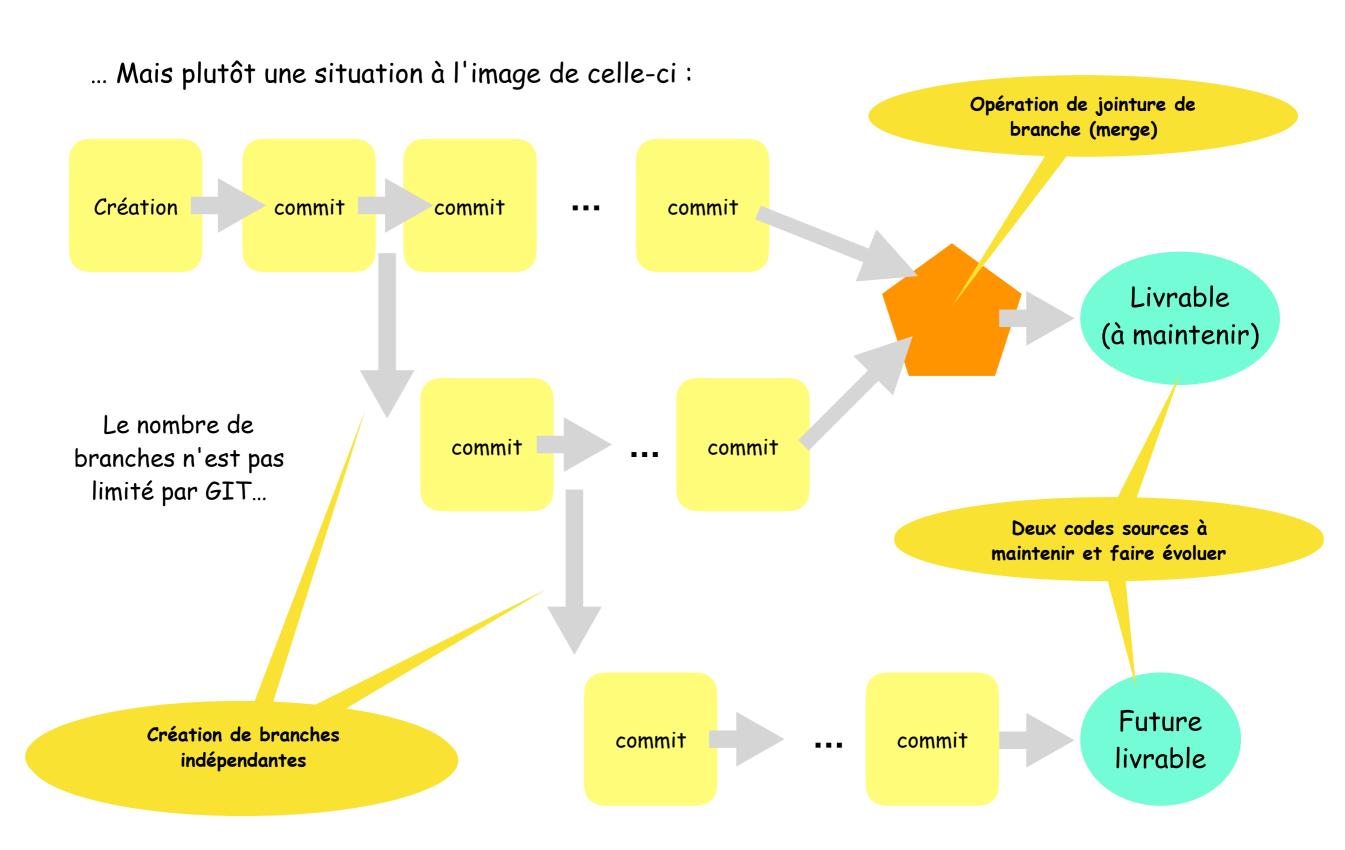
• ....

On a donc rarement cette démarche linéaire, surtout en mode « agile » (...) :



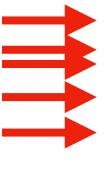












```
master
total 8
rw-r--r-- 1 fla staff 59 16 oct 11:49 README.md
rw-r--r-- 1 fla staff 287 16 oct 13:26 SIO_P2020_Etudiants.csv
diff --git a/SIO P2020 Etudiants.csv b/SIO P2020 Etudiants.csv
index d200988..78a5b75 100644
 -- a/SIO P2020 Etudiants.csv
+++ b/SIO P2020 Etudiants.csv
SIO - P2020 - Etudiants
```

Lister les branches existantes

Créer la branche "private"

Rendre la branche "private" active (HEAD)

Visualisation
des modifications dans la branche

Ajout des adresses e-mails dans le domaine @student-cs.fr





```
git commit -a -m "Ajout des adresses e-mail @student-cs.fr"
                                                                             Ce commit
[private ab16f6c] Ajout des adresses e-mail @student-cs.fr
1 file changed, 16 insertions(+), 16 deletions(-)
                                                                n'est visible que dans la branche "private"
rewrite SIO P2020 Etudiants.csv (82%)
$ git log --oneline
ab16f6c Ajout des adresses e-mail @student-cs.fr
7927006 Passage sous GIT
aa9790f Update README.md
2d2ded3 Add README.md
 git checkout master
Switched to branch 'master'
Your branch is up-to-date with '🖊 igin/master'.
$ git log --oneline
7927006 Passage sous GIT
aa9790f Update README.md
2d2ded3 Add README.md
                                                                              Modification
                                                                     du fichier dans la branche "master"
 vi SIO P2020 Etudiants.csv
 git commit -a -m "Modif. de l'en-tête du fichier"
[master 096f700] Modif. de l'en-tête du fichier
1_file changed, 2 insertions(+), 1 deletion(-)
```

→ Le fichier a subi des modifications dans les deux branches ...





#### La situation des commits est la suivante :

```
[$ git log --oneline --decorate --graph --all
 * 096f700 (HEAD -> master) Modif. de l'en-tête du fichier
 | * ab16f6c (private) Ajout des adresses e-mail @student-cs.fr
 |/
 * 7927006 (origin/master, origin/HEAD) Passage sous GIT
 * aa9790f Update README.md
 * 2d2ded3 Add README.md
```

Identifiants de commit permettent d'identifier la version du fichier

Graphe
(mode ascii) des branches et des commits
qui les composent

On peut remarquer l'attribution des lettres "a" et "b" pour identifier les deux versions en comparaison.

La différence fait bien état de toutes les modifications apportées indépendamment dans les deux branches.

```
--git a/SIO_P2020_Etudiants.csv b/SIO_P2020_Etudiants.csv
ndex 78a5b75...259df39 100644
   a/SIO P2020 Etudiants.csv
+++ b/SIO P2020 Etudiants.csv
@ -1,16 +1,17 @@
Nom; Prénom; e-mail local
```





Besoin de pouvoir opérer l'opération symétrique à la création de branche : la fusion de branches. Il s'agit de fusionner (merge) tous les fichiers avec leurs différences (\*).

Dans le cas présent l'opération est simple :



La fusion s'est accompagnée d'un commit du résultat (commentaire par défaut)

(\*) Cf le fonctionnement de la commande "patch" présentée dans les premiers slides.

git merge private uto-merging SIO P2020 Etudiants.csv Merge made by the 'recursive' strategy SIO\_P2020\_Etudiants.csv | 26 +++++++ 1 file changed, 13 insertions(+), 13 deletions(-) our branch is ahead of 'origin/master' by 3 commits. (use "git push" to publish your local commits) nothing to commit, working tree clean git diff SIO P2020 Etudiants.csv git log --oneline 3870 Merge branch 'private' 96f700 Modif. de l'en-tête du fichier ab16f6c Ajout des adresses e-mail @student-cs.fr 927006 Passage sous GIT a9790f Update README.md d2ded3 Add README.md cat SIO\_P2020\_Etudiants.csv iste des étudiant(e)s du MS-SIO - P2020 -Nom;Prénom;e-mail local DESMARCHELIER;Pierre;pierre.desmarchelier@student-cs.fr JOUKENG KENFACK;Roméo;romeo.djoukeng@student-cs.fr ABRE;Jérémie;jeremie.fabre@student-cs.fr OUBIOUX; Alan; alan, joubjoux@student-cs.fr .AMOTHE; François; francois.lamothe@student-cs.fr Y;Stéphane;stephane.ly@student-cs.fr GBANGO;Soulémanou;soulemanou.ngbango@student-cs.fr HERMINI;Acheq;acheq.rhermini@student-cs.fr CAËROU;Nicolas;nicolas.scaerou@student-cs.fr CHAPTCHET NOUDJET; Christian; christian.noudjet@student-cs.fr IRBAY;Djan - Laetiscia;djan.pirbay@student-cs.fr IA;David;david.tia@student-cs.fr 'INCENT;Etienne;etienne.vincent@student-cs.fr





Mettre à jour le dépôt distant

Suppression de la branche devenue (?) inutile

```
[$ git log --oneline
5923870 Merge branch 'private'
096f700 Modif. de l'en-tête du fichier
ab16f6c Ajout des adresses e-mail @student-cs.fr
7927006 Passage sous GIT
aa9790f Update README.md
2d2ded3 Add README.md
$ git branch -d private
Deleted branch private (was ab16f6c).
[$ git log --oneline
5923870 Merge branch 'private'
096f700 Modif. de l'en-tête du fichier
ab16f6c Ajout des adresses e-mail @student-cs.fr
7927006 Passage sous GIT
aa9790f Update README.md
2d2ded3 Add README.md
$ git branch
  master
$ git status
On branch master
Your branch is up-to-date with 'origin/master'.
nothing to commit, working tree clean
```



# Mastère SIO - Octobre 2019 - Projet Fil Rouge GIT - Travaux Dirigés



- 1. Se créer un compte sur <u>gitlab-student.centralesupelec.fr</u> avec l'e-mail @student-cs.fr;
- 2. Dans une fenêtre Terminal, configurer son outil git pour qu'il accède au dépôt /2008 laissus f/demo-git.git;
- 3. Vous avez dû recevoir un mail qui vous accorde le statut de développeur pour ce projet ;
- 4.Le but de TD est de modifier votre adresse e-mail (remplacer l'adresse par défaut par une autre, qui peut être fausse, peu importe) dans le fichier SIO\_P2O2O\_Etudiants.csv et de rendre la modification accessible à tous!
- 5.Enjoy GIT ;-)





#### Pourquoi JupyterNotebook/JupyterLab?

- IDE le plus utilisé actuellement dans la communauté 'data\*' (plus de 6 millions de downloads dans le monde) et est devenu "incontournable";
- · Existe depuis le début des années 2010, il est désormais stable ;
- JupyterNotebook (extension .jpynb) puis son évolution actuelle JupyterLab (cf https://jupyter.org et https:// jupyterlab.readthedocs.io/);
- · Mode client-serveur en local (ou distant);
- L'IHM est écrit en javascript (Framework phosphor.js) et exécutable dans tout browser web moderne;
- · Permet nativement de faire du Julia, du Python et du R;
- Déjà installé sur vos postes...





- C'est un environnement qui répond aux exigences des flux de travail dans le domaine des data-sciences et de la simulation;
- Une seule et unique instance permet à l'utilisateur d'écrire du code, de l'accompagner d'explications et de l'exécuter, mais aussi de visualiser des données, d'exécuter des calculs et de vérifier les résultats obtenus;
- · Le code s'écrit par cellules, plus ou moins complexes selon les besoins ;
- Le code peut s'exécuter pas à pas, dans chaque cellule, et permet un prototypage des projets particulièrement puissant, puisque le développeur peut interagir avec son code à chaque ligne/cellule écrite sans remettre en cause tout ce qui a été exécuté (un peu comme sous un debugeur);





Au SIO il s'exécute en mode locale à partir d'un "launcher" qui se nomme « Anaconda Navigator »



Celui-ci est une sur-couche d'un gestionnaires de paquets pour Python et R nommé « conda ».

On peut ignorer conda dans un premier temps, le navigateur permet d'effectuer toutes les tâches essentielles (gestion des paquets logiciels, des environnements ...).





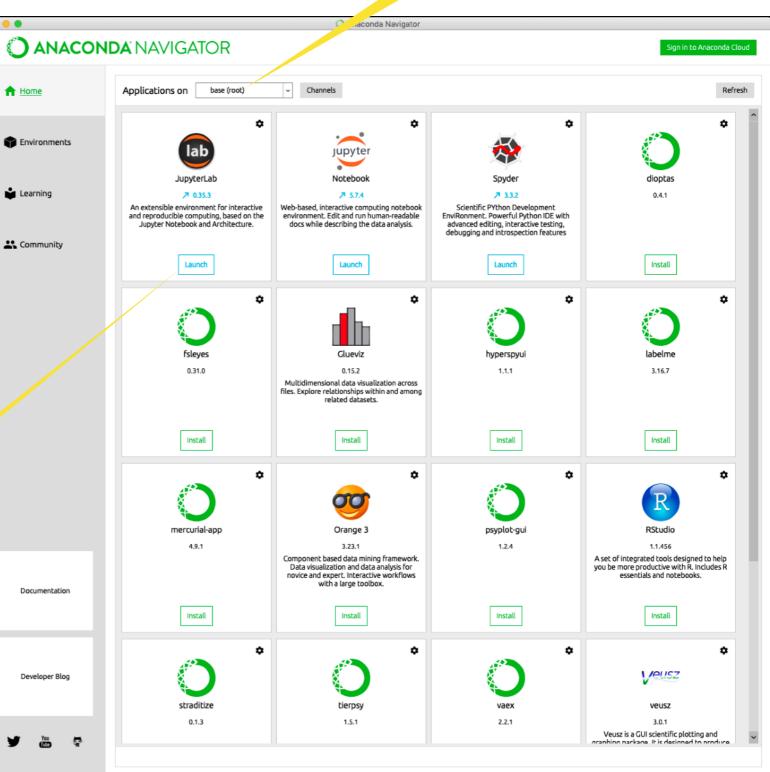
Choix d'un environnement de travail

La fenêtre d'accueil

Gestion du contenu des environnements de travail (ajout/retrait/modifications)

Divers documentations

L'outil qui nous intéresse...





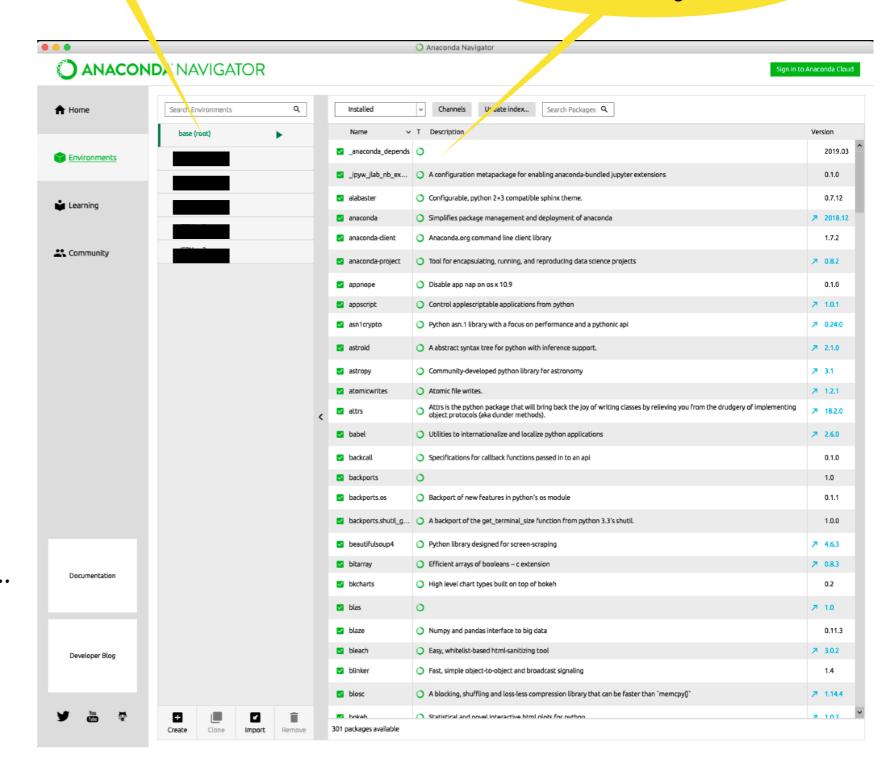


L'environnement par défaut

Les outils (packages)
installés vs existants et à
télécharger

L'onglet de gestion des environnements

C'est à dire :
Un ensemble complet
d'outils par exemple
dédiés à Python 2.x
ou à Python 3.x
ou à un client particulier...

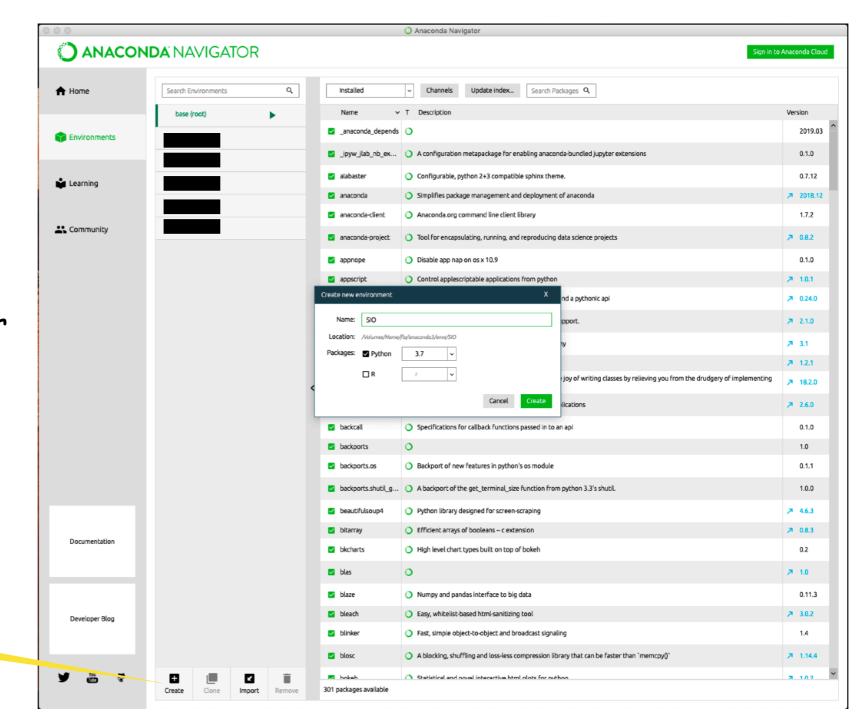






Il est recommandé
de se créer un
environnement
différent par
projet pour pouvoir
faire évoluer les
outils de manière
indépendante...

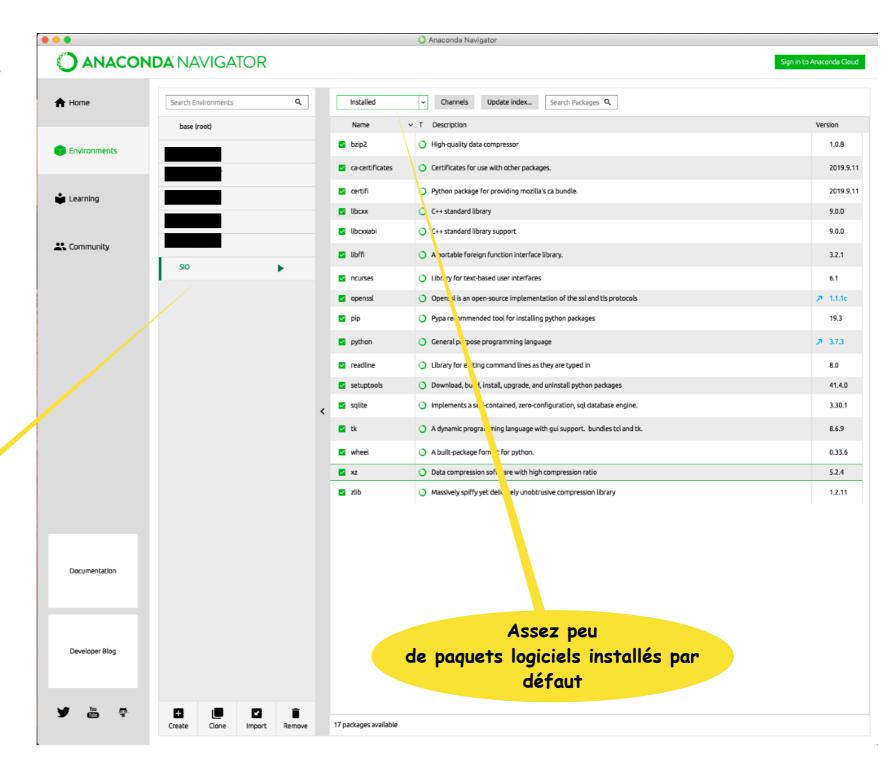
Créer un nouvel environnement







Le nouvel environnement SIO juste crée :



Nouvelle environnement "SIO"





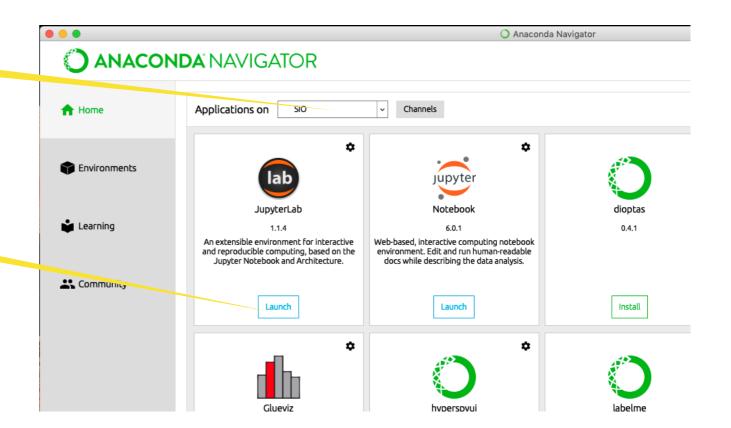
À sélectionner plutôt que "Base"

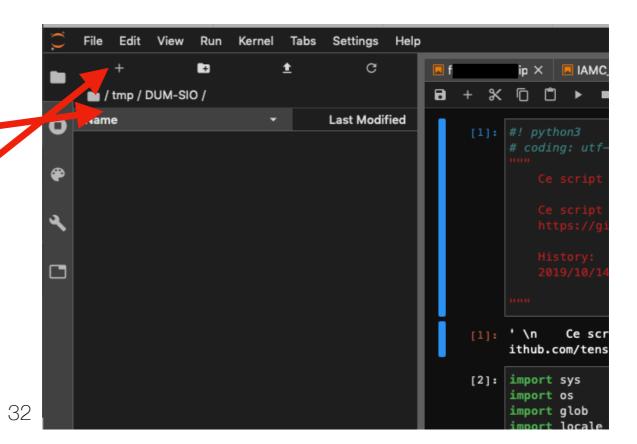
Cliquer sur "Install" la première fois!

L'IDE s'ouvre dans le browser par défaut.

Il faut choisir un répertoire pour son projet

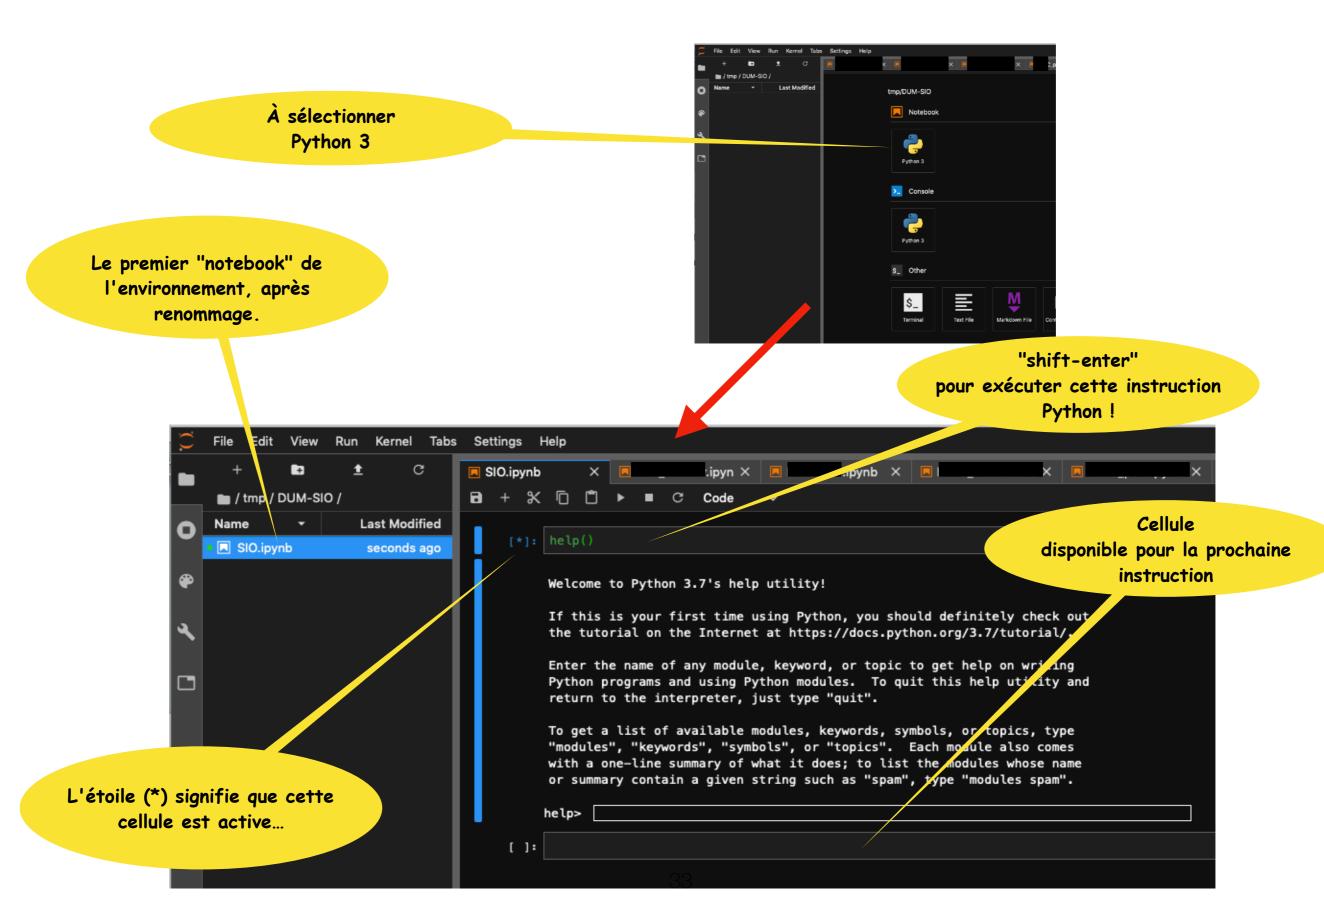
Puis créer un fichier (ici le répertoire est vide)















Suite avec l'utilisation des APIs pour se connecter sur RosettaHUB